

Proposta de Projeto Final - Tópicos Avançados em Controle processos de sinais IV

Felipe Meier Martins - 22100504
Vitor Rodrigues Scharf - 22100867

Descrição da tarefa

Este projeto tem como objetivo desenvolver um sistema de classificação supervisionada aplicado a sinais de eletrocardiograma (ECG) de 12 derivações, com foco na identificação automática de condições cardíacas presentes no momento do exame. Trata-se de uma tarefa de classificação multi-rótulo, uma vez que um mesmo sinal pode estar associado a múltiplos diagnósticos simultaneamente, como infarto agudo do miocárdio, distúrbios de condução ou alterações no segmento ST.

A partir da estrutura desenvolvida em um trabalho anterior da disciplina, que utilizou redes neurais convolucionais (CNNs) aplicadas diretamente ao sinal bruto, buscamos explorar novas abordagens de modelagem e análise com o intuito de aprimorar os resultados obtidos. Entre as possibilidades que pretendemos discutir e eventualmente implementar ao longo do projeto, destacam-se o uso de diferentes arquiteturas de redes neurais, como RNNs, a aplicação de técnicas de pré-processamento, como filtragem e extração de características relevantes do sinal (por exemplo, os intervalos R-R), bem como a experimentação com funções de perda alternativas, como a Focal Loss, visando melhorar o desempenho do modelo em classes menos representadas.

A escolha final das técnicas a serem utilizadas será feita em conjunto com o professor, com base na relevância técnica, na viabilidade computacional e na adequação ao escopo da disciplina.

Motivação

A tarefa proposta neste projeto está diretamente alinhada com o profundo interesse dos autores em aplicar os conhecimentos adquiridos ao longo do curso de engenharia elétrica e engenharia eletrônica na área da saúde, especialmente no desenvolvimento de tecnologias que possam contribuir com o diagnóstico e o acompanhamento clínico de pacientes. A análise automatizada de sinais de ECG é uma aplicação concreta e relevante, uma vez que esse exame é amplamente utilizado na prática médica e sua interpretação exige conhecimento especializado, nem sempre disponível em tempo hábil em todos os contextos clínicos.

Diversos trabalhos da literatura já demonstraram que modelos baseados em aprendizado supervisionado, especialmente redes neurais profundas, são capazes de identificar padrões eletrocardiográficos com alta acurácia, muitas vezes alcançando desempenho comparável ao de cardiologistas. O uso de sinais de ECG de 12 derivações como entrada para modelos

de classificação multi-rótulo tem se mostrado promissor, com bons resultados relatados em artigos como os de Strodthoff et al. (2021) e Smigiel et al. (2021), além de aplicações práticas em projetos anteriores da própria disciplina. Esses trabalhos demonstram de forma clara que é viável prever os diagnósticos a partir dos dados de entrada disponíveis, reforçando a relevância e a viabilidade da proposta.

Além do valor acadêmico, projetos como este têm potencial de impacto social e clínico ao viabilizar ferramentas auxiliares que possam ser integradas a sistemas de triagem, monitoramento remoto ou suporte à decisão médica, contribuindo para diagnósticos mais rápidos, redução de erros e ampliação do acesso à saúde.

Descrição dos dados

O projeto utilizará o conjunto de dados **PTB-XL**, disponibilizado publicamente no portal PhysioNet. Trata-se de uma base composta por 21.837 registros de ECG de 10 segundos, obtidos de pacientes com diferentes condições clínicas. Cada sinal é gravado com 12 derivações simultâneas, totalizando 12 canais por amostra, com frequência de amostragem de 100 Hz.

As **variáveis de entrada** são sequências numéricas contínuas representando os sinais de ECG capturados por cada uma das derivações padrão (I, II, III, aVR, aVL, aVF, V1–V6). Cada registro de entrada tem dimensão 1000×12 (1000 amostras por canal, 12 canais), e os sinais são padronizados e normalizados conforme procedimentos descritos pelos autores da base.

As **variáveis de saída** são rótulos diagnósticos atribuídos por especialistas, podendo incluir múltiplos diagnósticos por exame (ou seja, trata-se de um problema de classificação multi-rótulo). Os rótulos são organizados em cinco superclasses principais:

- **NORM** (traçado normal),
- **MI** (infarto do miocárdio),
- **STTC** (alterações do segmento ST/T),
- **CD** (distúrbios de condução),
- **HYP** (hipertrofia).

Além dessas, a base também fornece subclasses mais específicas, que poderão ser exploradas caso a abordagem do projeto evolua para classificações mais detalhadas, além de outros dados do paciente como id do paciente, idade e sexo.

A estrutura da base, com sinais multicanais sincronizados e rótulos clínicos validados, torna o PTB-XL especialmente adequado para tarefas de aprendizado supervisionado aplicadas à medicina.

Métricas

Como se trata de um problema de classificação multi-rótulo, o desempenho dos modelos será avaliado utilizando métricas adequadas a esse tipo de tarefa. Entre as principais métricas que pretendemos utilizar estão:

- **AUC-ROC por classe (Área sob a Curva ROC):** mede a capacidade do modelo em distinguir corretamente entre a presença e a ausência de cada diagnóstico individualmente. É especialmente útil em problemas desbalanceados, como este, em que algumas classes ocorrem com muito mais frequência que outras.
- **F1-score (micro e macro):** avalia o equilíbrio entre precisão e recall. O F1-micro considera todas as previsões igualmente e é útil para observar o desempenho global, enquanto o F1-macro dá o mesmo peso a cada classe, o que é importante para avaliar o comportamento do modelo em classes minoritárias.
- **Precision e Recall por classe:** permitem uma análise mais detalhada da performance do modelo em cada diagnóstico, identificando se o modelo tende a errar por excesso de falsos positivos ou falsos negativos.
- **Acurácia geral:** será calculada apenas como referência, mas não será a métrica principal, já que pode ser enganosa em contextos com forte desbalanceamento de classes.

Além dessas métricas, também pretendemos visualizar matrizes de confusão binárias por classe e acompanhar as curvas de perda e de validação ao longo do treinamento, como forma de avaliar o comportamento do modelo e detectar possíveis problemas de overfitting.

Trabalhos relacionados

Três trabalhos principais da literatura servem como referência para o desenvolvimento deste projeto, todos utilizando o conjunto de dados PTB-XL e abordando a tarefa de classificação automática de sinais de ECG por meio de redes neurais.

O primeiro é o projeto desenvolvido por **Sofia Klautau (2024)**, no contexto da mesma disciplina. Nele, foi implementada uma arquitetura de rede neural convolucional (CNN) simples para realizar inicialmente a classificação multi-classe e, posteriormente, uma adaptação para a tarefa de classificação multi-rótulo. O trabalho também aplicou **técnicas de otimização de hiperparâmetros com Optuna**, além de apresentar uma análise detalhada por classe. Essa implementação será utilizada como base inicial para o presente projeto.

O segundo trabalho é o artigo de **Smigiel et al. (2021)**, publicado na revista *Entropy*. Nele, os autores comparam três arquiteturas diferentes aplicadas ao PTB-XL: uma CNN convencional, uma CNN com atributos baseados em medidas de entropia, e a rede SincNet, originalmente desenvolvida para aplicações em sinais de voz. Embora a tarefa principal seja formulada como classificação multi-classe, o artigo é relevante por explorar estratégias

como a extração de características e a comparação de modelos leves. Até o momento, não foi encontrada uma implementação oficial pública deste artigo.

O terceiro trabalho de referência é o artigo de **Strodthoff et al. (2021)**, publicado no *IEEE Journal of Biomedical and Health Informatics*. Ele apresenta um benchmark abrangente para o PTB-XL, formulando a tarefa corretamente como **classificação multi-rótulo**, e avaliando o desempenho de diferentes arquiteturas, como CNNs profundas e ResNets. Esse artigo é particularmente relevante por estabelecer **métricas padronizadas** e protocolos de avaliação amplamente adotados pela comunidade. Os autores disponibilizaram uma implementação oficial em GitHub, o que facilita a reprodução e a comparação dos resultados.

Esses três trabalhos fornecerão tanto a base prática quanto o embasamento teórico necessário para o desenvolvimento do projeto, além de servirem como pontos de comparação para as abordagens que serão testadas.

Objetivos

Este projeto tem como objetivo aprimorar a classificação multi-rótulo de sinais de ECG utilizando a base PTB-XL, a partir de um modelo inicial baseado em redes neurais convolucionais. Buscaremos explorar diferentes estratégias para enriquecer a representação dos sinais e melhorar o desempenho do modelo, especialmente em classes menos frequentes.

Entre as abordagens em consideração estão a extração de características clínicas relevantes, como intervalos R-R, variabilidade entre batimentos e morfologia do complexo QRS, além da aplicação de técnicas de pré-processamento e transformadas no domínio tempo-frequência. Também pretendemos avaliar o uso de outras arquiteturas, como redes recorrentes, e testar funções de perda mais robustas ao desbalanceamento, como a Focal Loss.

Em caso de sucesso, As etapas seguintes incluirão a exploração de predições adicionais, como prognósticos de complicações e riscos de readmissão, com a possibilidade de junção com outro dataset, com base na viabilidade e orientação do professor, sempre buscando justificar as decisões com análises comparativas e métricas apropriadas.

Metodologia

A metodologia será baseada em uma arquitetura convolucional simples utilizada em um trabalho anterior da disciplina, que servirá como referência inicial para o desenvolvimento do modelo. A partir dessa base, pretendemos explorar diferentes variações, como o uso de redes recorrentes (RNNs), redes neurais convolucionais (CNN, a princípio a melhor abordagem) ou redes profundas, a extração de características específicas do sinal, como intervalos R-R e variabilidade entre batimentos, o uso de transformadas no domínio tempo-frequência, além da aplicação de funções de perda mais adequadas ao desbalanceamento, como a Focal Loss.

As abordagens serão escolhidas ao longo do projeto, de acordo com a viabilidade e a orientação do professor. Os modelos serão avaliados de forma comparativa, utilizando

métricas como AUC, F1-score e precision-recall por classe, com o objetivo de identificar quais estratégias trazem ganhos reais de desempenho.

Transparência

Este projeto é exclusivo da disciplina Tópicos Avançados em Controle e Processamento de Sinais IV e **não está vinculado a nenhuma outra disciplina, estágio, trabalho de conclusão de curso ou projeto externo**. Não há participação de outras pessoas além dos integrantes da equipe inscritos na disciplina.

Referências

KLAUTAU, Sofia Pinheiro. *Deep Learning for Classification of 12-lead ECG Signals*. Projeto final da disciplina Tópicos Avançados em Controle e Processamento de Sinais IV – UFSC, 2024.

SMIGIEL, S.; ŚLĘŻYŃSKI, P.; KRZYWORZEKA, P.; ZAGRODZKI, P. *ECG Signal Classification Using Deep Learning Techniques Based on the PTB-XL Dataset*. *Entropy*, v. 23, n. 9, 1121, 2021. DOI: [10.3390/e23091121](https://doi.org/10.3390/e23091121)

STRODTHOFF, N.; WAGNER, P.; SCHAEFFTER, T.; SAMEK, W. *Deep Learning for ECG Analysis: Benchmarks and Insights from PTB-XL*. *IEEE Journal of Biomedical and Health Informatics*, v. 25, n. 5, p. 1519–1528, 2021. DOI: 10.1109/JBHI.2020.3022989

DAS, S.; SANTOSH, K. C.; PAL, U. Deep learning for ECG arrhythmia detection and classification: An overview of progress for period 2017–2023. *Frontiers in Physiology*, v. 14, p. 1246746, 2023. DOI: 10.3389/fphys.2023.1246746

DE LIMA, F. F.; DOS SANTOS, M. A.; RODRIGUES, M. C. ECG signal classification using various machine learning techniques. *Journal of Medical Systems*, v. 42, n. 8, p. 143, 2018. DOI: 10.1007/s10916-018-1083-6